

Chapter 6. 线性方程组的解法:

前提: 线性方程组的解存在且唯一: 系数矩阵行列式 $\neq 0$

线性方程组的两种解法:

① 直接求解: 精确解: 适用于低阶稠密方程组

② 迭代法: 逐步逼近精确解, 大型稀疏方程组

§1 向量与矩阵范数: 为估计误差而用

向量范数 n 维向量 R^n

如果向量 $X \in R^n$ 的某实值函数 $N(X) = \|X\|$ 满足条件:

1. $\|X\| \geq 0$ $\|X\| = 0$ 时, 当且仅当 $X = 0$ 成立.

2. $\|\alpha X\| = |\alpha| \|X\| \quad \forall \alpha \in R$ 标量

3. $\|X+Y\| \leq \|X\| + \|Y\|$ 三角不等式

则称 $N(X)$ 是向量 X 的范数

1. 无穷范数: ∞ 范数 $\|X\|_\infty = \max_{1 \leq i \leq n} |x_i|$

2. 1 范数: $\|X\|_1 = \sum_{i=1}^n |x_i|$

3. 2 范数 $\|X\|_2 = \left(\sum_{i=1}^n x_i^2 \right)^{\frac{1}{2}}$

4. p 范数 $\|X\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$

向量序列 $\{x^{(k)}\}$ 收敛于向量 X^* 是指对每一个 $1 \leq i \leq n$ 都有:

$\lim_{k \rightarrow \infty} x_i^{(k)} = x_i^*$ 每个分量 $x_i^{(k)}$ 都收敛到 x_i^* 充要条件.

也等价于 $\Leftrightarrow \lim_{k \rightarrow \infty} \|x^{(k)} - X^*\|_\infty = 0$ 即无穷范数收敛到 0

若存在常数 $C > 0$, 对 $\forall X \in R^n$ 有 $\|X\|_A \leq C \|X\|_B$ 则称范数 $\| \cdot \|_A$ 比范数 $\| \cdot \|_B$ 强, 若 $\| \cdot \|_A$ 比 $\| \cdot \|_B$ 强同时 $\| \cdot \|_B$ 也比 $\| \cdot \|_A$ 强, 即 $\frac{1}{C} \|X\|_B \leq \|X\|_A \leq C \|X\|_B$.

定理: R^n 上一切范数都是等价的

定理: $N(X) = \|X\|$ 为 R^n 上任何范数, 则 $N(X)$ 为分量 X_i 的连续函数

矩阵范数:

$m \times n$ 的空间的矩阵范数 $\| \cdot \|$ 满足:

(1) 正定 $\|A\| \geq 0$ $\|A\| = 0$ 时当且仅当 $A = 0$

(2) 齐次: $\|\alpha A\| = |\alpha| \|A\|$ 对 $\forall \alpha \in C$ 成立

(3) 三角不等式: $\|A+B\| \leq \|A\| + \|B\|$

(4) 相容: $\|AB\| \leq \|A\| \cdot \|B\|$

Frobenius 范数: $\|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^m |a_{ij}|^2}$

算子范数: (导出范数): 由向量的 p 范数导出的关于矩阵的 p 范数.

$$\|A\|_p = \max_{\vec{x} \neq \vec{0}} \frac{\|A\vec{x}\|_p}{\|\vec{x}\|_p}$$

无穷范数 $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^m |a_{ij}|$ 最大行和、行和范数

$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$ 最大列和、列和范数

ATA的最大的特征值

 $\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$ 谱范数: 最大特征值(谱半径)平方.谱: $\{\lambda_1, \lambda_2, \dots, \lambda_n\}$ F范数不是一个算子范数: 假设是由 p -范数导出, 取 $A=I$, 则 $\|I\|_F = 1$, 但 $\|I\|_p = n^{1/p}$ 谱半径: $\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$ 定理: 对 \forall 算子范数: $\rho(A) \leq \|A\|$ 谱半径 \leq 范数由范数的相容性: $\|Ax\| \leq \|A\| \|x\|$, 将任意一个特征根 λ 与对应的特征向量 u 代入: $Au = \lambda u$.

$$|\lambda| \|u\| = \|\lambda u\| = \|Au\| \leq \|A\| \|u\|$$

$$\Rightarrow |\lambda| \leq \|A\| \quad \text{谱半径} \leq \text{范数}$$

定理: 若 A 对称, 则 $\|A\|_2 = \rho(A)$ A 对称: 则 $A^T = A$. λ 是 A 的特征值.则 λ^2 必然是 A^2 的特征值: $\lambda x = Ax \quad A^2 x = A \lambda x = \lambda Ax = \lambda^2 x$ $\lambda \rightarrow A$ 特征值 $\lambda^2 \rightarrow A^2$ \dots $\lambda^n \rightarrow A^n$ $f(\lambda) \rightarrow f(A)$ $f(\lambda)$ 是多项式函数.定理: 若矩阵 B 对某个算子范数满足 $\|B\| < 1$, 则 $I \pm B$ 可逆.要记住

$$\|(I \pm B)^{-1}\| \leq \frac{1}{1 - \|B\|}$$

§2. 高斯消元法: 直接求解法.

$$AX=b.$$

先将A化成一个上三角阵, 然后回代求解.

相当于对增广矩阵 $(A|b)$ 作初等行变换变成上三角矩阵.

理: 如果A为n阶非奇异矩阵, 即A的行式不等于0, 则可通过Gauss消元.

将方程化为三角形方程组.

理: $a_{ii}^{(i)} \neq 0$ 的必要条件是矩阵A的顺序主子式 $D_i \neq 0$. 则:

$$D_i = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1i} \\ \vdots & \vdots & & \vdots \\ a_{i1} & a_{i2} & \cdots & a_{ii} \end{vmatrix}$$

不需要交换两行就可以完成Gauss消元.

§3. 选主元消去法:

在Gauss消元过程中先找到该列中绝对值最大的元素, 将其作为主元. 交换到第一行, 然后其它行再减去这一行的倍数.

§4. 高斯消元法: LU分解. 由Gauss消元导出的LU分解.

高斯消元的矩阵形式:

$$l_{ii} = \frac{a_{ii}}{a_{ii}}$$

LU分解: L: 下三角 U: 上三角:

L: 下三角并且对角线上元素全为1: 单位下三角

$$\cancel{L_1} L_{n-1} \dots L_2 L_1 A = U \Rightarrow A = \underbrace{L_1^{-1} L_2^{-1} \dots L_{n-1}^{-1}}_L U$$

$$AX=b, A=LU, A \text{ 非奇异}$$

$$\Rightarrow LUX=b \Rightarrow \begin{cases} UX=Y \\ LY=b \end{cases} \quad L, U \text{ 均为三角形的, 所以会容易求解.}$$

定理: A为n阶方阵, 如果A的顺序主子式D_k≠0, 则A的LU分解唯一
其中L为单位下三角.

假设不唯一, 则 $A = L_1 U_1 = L_2 U_2$

两边左乘 L_1^{-1} 右乘 U_2^{-1}

$$L_1^{-1} L_1 U_1 U_2^{-1} = L_1^{-1} L_2 U_2 U_2^{-1}$$

$$U_1 U_2^{-1} = L_1^{-1} L_2$$

上三角 单位下三角 所以必为单位矩阵I.

$$\therefore U_1 U_2^{-1} = L_1^{-1} L_2 = I \Rightarrow \begin{cases} L_1 = L_2 \\ U_1 = U_2 \end{cases}$$

道特分解法——LU分解的紧凑格式, (直接分解法).

通过比较法直接导出L和U的计算公式

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} 1 & & & \\ l_{21} & 1 & & \\ & \ddots & \ddots & \\ l_{n1} & & & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ & \ddots & & \\ & & \ddots & \\ & & & u_{nn} \end{bmatrix}$$

先求 U 的第一行, 再求 L 的第一列, 再求 U 的第二行, L 的第二列, ...

$$\Rightarrow a_{ij} = \sum_{k=1}^{\min(i,j)} l_{ik} u_{kj}$$

U 的第一行, L 的第一列.

U 的第二行, L 的第二列

... 继续下去, 可直接求出 L 和

又称 直接三角分解法.

如果需要交换两行 (在 Gauss 消元过程中), 则不能直接得到 LU 分解.

但是可以实现: $PA=LU$

相当于将某些行交换之后, 就符合之前的条件, 可以进行 LU 分解.

平方根法: 适用于 对称, 正定矩阵 的分解法.

对称矩阵: $A^T = A$, $a_{ij} = a_{ji}$

正定矩阵: $x^T A x > 0$ 对 $\forall x \neq 0$ 都成立

对称

正定矩阵则:

(1) A^{-1} 也是对称正定, 且 $a_{ii} > 0$ (2) A 的任意主子阵 A_K 亦对称正定.(3) A 的特征值 $\lambda_i > 0$ (4) A 的全部主子式 $\det(A_K) > 0$ $A^{-1} A_K, \lambda_i > 0$ $|A_K| > 0$

$$U = \begin{bmatrix} \diagup & & \\ & u_{ij} & \\ & & \diagdown \end{bmatrix} = \begin{bmatrix} u_{11} & & \\ & u_{22} & \\ & & \ddots \\ & & & u_{nn} \end{bmatrix} \begin{bmatrix} 1 & & & u_{ij}/u_{ii} \\ & 1 & & \\ & & \ddots & \\ & & & 1 \end{bmatrix}$$

$D \quad \tilde{U}$

对于对称正定矩阵 A :

$$\begin{cases} A \text{ 对称: 则有 } A = LU = LD\tilde{U} \\ A^T = A \end{cases} \Rightarrow L = \tilde{U}^T$$

即 $A = LD\tilde{U} = LD\tilde{U}^T$ 又由于 A 正定, 则 $u_{11} u_{22} \cdots u_{nn} > 0$

$$\text{记 } D^{1/2} = \begin{bmatrix} \sqrt{u_{11}} & & \\ & \sqrt{u_{22}} & \\ & & \ddots \\ & & & \sqrt{u_{nn}} \end{bmatrix} \text{ 则 } \tilde{L} = LD^{1/2} \text{ 仍是下三角阵.}$$

记.

$$A = LD\tilde{U}^T \text{ 可化为 } A = \tilde{L} \tilde{U}^T$$

设矩阵 A 对称正定, 则存在非奇异的下三角阵 $L \in \mathbb{R}^{n \times n}$, 使得 $A = LL^T$
若限定 L 对角元为正, 则分解唯一:

追赶法解三对角方程组:

$$A: \begin{bmatrix} b_1 & c_1 & & \\ a_2 & b_2 & c_2 & \\ & a_3 & \ddots & c_n \\ & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{bmatrix}$$

对A作 Crout 分解: Crout 分解: 仍是LU的分解, 只是U为单位上三角

$$A = \underbrace{\begin{bmatrix} \alpha_1 & & & \\ r_2 & \alpha_2 & & \\ & \ddots & \ddots & \\ & & r_n & \alpha_n \end{bmatrix}}_L \underbrace{\begin{bmatrix} 1 & \beta_1 & & \\ & 1 & \beta_2 & \\ & & \ddots & \beta_{n-1} \\ & & & 1 \end{bmatrix}}_U$$

$$\Rightarrow \begin{cases} r_i = a_i \\ \beta_i = \frac{c_i}{\alpha_i} \\ \alpha_i = b_i - r_i \beta_{i-1} \end{cases}$$

$$A = LU \Leftrightarrow \begin{cases} \tilde{U}x = Y = \tilde{f} \\ \tilde{L}Y = f \end{cases}$$

对角占优矩阵: $A: n \times n$:

$$\left\{ \begin{array}{l} ① |a_{ii}| \geq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \\ ② \text{至少对于某一个 } k, |a_{kk}| > \sum_{\substack{j=0 \\ j \neq k}}^n |a_{kj}| \end{array} \right.$$

严格对角占优:

$$|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|$$

定理: 若 A 为严格对角占优的反对称阵, 且满足:

$$|b_i| > |c_i| > 0 \quad |b_n| > |a_n| > 0 \quad a_i \neq 0 \quad c_i \neq 0$$

则追赶法可以求解以 A 为系数矩阵的方程组.

§5. 线性方程组的误差分析:

直接求解理论上不会有误差, 但会由计算机引起误差.

矩阵 A 的条件数: $\|A\| \cdot \|A^{-1}\|$ 条件数越大, 越难求得精确解.

常用条件数: $\text{cond}(A)$, $\text{cond}(A)_1$, $\text{cond}(A)_2$

$$\text{若 } A \text{ 对称, 则 } \text{cond}(A)_2 = \|A\|_2 \cdot \|A^{-1}\|_2 = \frac{\max |\lambda|}{\min |\lambda|} = \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}}$$

$$= \sqrt{\lambda_{\max}(A^T A)} \cdot \sqrt{\lambda_{\max}(A^{-1})^T A^{-1}}$$

$$\text{由: } |\lambda I - AB| = |A| |\lambda A^{-1} - B| = |A| \cdot |\lambda I - BA| |A^{-1}| \stackrel{\Delta}{=} 0$$

$\therefore AB$ 和 BA 的特征值相同

λ 是 A 的特征值, 则 $\frac{1}{\lambda}$ 是 A^{-1} 的特征值

$$(A^T A)^T = A^T (A^T)^T = (A^T)^T A^T = A^T$$

条件数的性质:

(1) A 可逆, 则 $\text{cond}(A)_p \geq 1$ $\|A\|_p \|A^{-1}\|_p \geq \|A \cdot A^{-1}\|_p = 1$ 范数相容性

(2) A 可逆, $\alpha \in \mathbb{R}$ 则 $\text{cond}(\alpha A) = \text{cond}(A)$ $\alpha \neq 0$

$$\text{cond}(\alpha A) = \|\alpha A\| \|\alpha A^{-1}\| = |\alpha| \|A\| |\alpha|^{-1} \|A^{-1}\| = \|A\| \|A^{-1}\| = \text{cond}(A)$$

齐次性质

(3) A 正交: $\text{cond}(A)_2 = 1$

A 正交: $A^T A = I$

$$\text{cond}(A)_2 = \|A\|_2 \|A^{-1}\|_2$$

$$= \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}} = 1$$

(4) A 可逆, R 正交, 则 $\text{cond}(RA)_2 = \text{cond}(AR)_2 = \text{cond}(A)_2$

$$\text{cond}(RA)_2 = \sqrt{\frac{\lambda_{\max}[(RA)^T RA]}{\lambda_{\min}[(RA)^T (RA)]}} = \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}} = \text{cond}(A)_2$$

可以用来衡量方程的病态程度: 若 A 的条件数很大, 则病态的, A 或 b 的微小扰动都会给方程的解造成很大的影响

近似解的误差估计及改善

$AX=b$ 的近似解为 X^*

误差 $r = b - AX^*$

由: $\frac{\|X - X^*\|}{\|X\|} \leq \text{cond}(A) \frac{\|r\|}{\|b\|}$

改善方法: (1) $AX=b \Rightarrow X_1$

(2) $r = b - AX_1$

(3) $Ad_1 = r_1 \Rightarrow d_1$

(4) $X_2 = X_1 + d_1$

§6. 解线性方程组的迭代方法:

求解 $AX=b$, 思路:

将 $AX=b$ 等价改写为 $X=BX+f$ 的形式, 建立迭代 $X^{(k+1)} = BX^{(k)} + f$

从初值 $X^{(0)}$ 出发, 得到序列 $\{X^{(k)}\}$ B : 迭代矩阵, 适用于大型稀疏矩阵

Jacobi 法和 Gauss-Seidel 法:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n \end{cases} \quad a_{ii} \neq 0 \Rightarrow \begin{cases} x_1 = \frac{1}{a_{11}}(-a_{12}x_2 - \dots - a_{1n}x_n + b_1) \\ x_2 = \frac{1}{a_{22}}(-a_{21}x_1 - \dots - a_{2n}x_n + b_2) \\ \vdots \\ x_n = \frac{1}{a_{nn}}(-a_{n1}x_1 - \dots - a_{nn}x_{n-1} + b_n) \end{cases}$$

迭代形式: $x_i^{(k+1)} = \frac{1}{a_{ii}}(b_i - \sum_{j=1, j \neq i}^n a_{ij}x_j^{(k)})$

写成矩阵形式: 记 $A = \begin{bmatrix} \text{---} & & \\ & D & \\ \text{---} & & \end{bmatrix} = L + U$ 将 A 分成三块, L, D, U . 将 A 变成逆之和

$$AX=b \Rightarrow (D+L+U)X=b$$

$$DX = -(L+U)X + b$$

$$X = \underbrace{-D^{-1}(L+U)X}_B + \underbrace{D^{-1}b}_f$$

Jacobi迭代阵: $-D^{-1}(L+U)$ 记作 B_J

$$X^{(k+1)} = -D^{-1}(L+U)X^{(k)} + D^{-1}b$$

Jacobi迭代计算: $X_1^{(k+1)}, X_2^{(k+1)}, \dots, X_n^{(k+1)}$.

计算每一个 $X_i^{(k+1)}$ 都只用到 $X_i^{(k)}$, 不会用到 $X_{i-1}^{(k+1)}, X_{i+1}^{(k+1)}, \dots$ 这些刚求出来的最新值, 所以Jacobi迭代可以修改.

所以可以将迭代过程中求 $X_i^{(k+1)}$ 时, 对右边 $X_{i-1}^{(k)}, X_{i+1}^{(k)}, \dots$ 改用新求出来的 $X_{i-1}^{(k+1)}, X_{i+1}^{(k+1)}, \dots$

由此导出 Gauss-Seidel 迭代:

$$X_1^{(k+1)} = \frac{1}{a_{11}} (-a_{12}X_2^{(k)} - a_{13}X_3^{(k)} - \dots - a_{1n}X_n^{(k)} + b_1)$$

$$X_2^{(k+1)} = \frac{1}{a_{22}} (-a_{21}X_1^{(k+1)} - a_{23}X_3^{(k)} - \dots - a_{2n}X_n^{(k)} + b_2)$$

....

$$X_n^{(k+1)} = \frac{1}{a_{nn}} (-a_{n1}X_1^{(k+1)} - a_{n2}X_2^{(k+1)} - \dots - a_{n,n-1}X_{n-1}^{(k+1)} + b_n)$$

$$X^{(k+1)} = -D^{-1}(LX^{(k+1)} + UX^{(k)}) + D^{-1}b$$

$$X^{(k+1)} = -(D+L)^{-1}UX^{(k)} + (D+L)^{-1}b$$

两种方法都有收敛性问题:

Jacobi迭代 $X^{(k+1)} = -D^{-1}(L+U)X^{(k)} + D^{-1}b$

Gauss-Seidel迭代: $X^{(k+1)} = -(D+L)^{-1}UX^{(k)} + (D+L)^{-1}b$

§7. 迭代法的收敛性:

$X^{(k+1)} = BX^{(k)} + f$ 的收敛条件:

X^* 记为准确解: $e^{(k+1)} = X^{(k+1)} - X^*$

$$= (BX^{(k)} + f) - (BX^* + f)$$

$$= B(X^{(k)} - X^*) = Be^{(k)}$$

$\therefore \boxed{e^{(k)} = B^k e^{(0)}}$ $e^{(0)} = X^* - X^{(0)}$ $X^{(0)}$ 是随意给的初始值

$e^{(k)} \rightarrow 0$ $e^{(k)}$ 是一个向量, 即要求 $e^{(k)}$ 的每一个分量收敛到 0

也即 $\|e^{(k)}\| = 0$. $e^{(k)}$ 的向量范数收敛到 0

定理: $X = BX + f$ 存在唯一解. 则从任意 $X^{(0)}$ 出发, 迭代 $X^{(k+1)} = BX^{(k)} + f$

收敛 $\iff \boxed{B^k \rightarrow 0}$ 充要条件.

矩阵 A_k 收敛到 A : $\lim_{k \rightarrow \infty} A_k = A$ 是指 $\lim_{k \rightarrow \infty} a_{ij}^{(k)} = a_{ij}$ 对所有 $1 \leq i, j \leq n$

即每一个元素对应收敛

等价于 $\|A_k - A\| \rightarrow 0$ 对于任意范数成立

定理 $B^k \rightarrow 0 \iff \rho(B) < 1$: 转化为求迭代矩阵 B 的谱半径/特征值, 充要

前面有: 谱半径 < 范数: λ 是 B 的特征值, 则 λ^k 一定是 B^k 的特征值

迭代法基本定理: $X = BX + f$

注意到:

$$\begin{aligned} e^{(k+1)} &= x^{(k+1)} - x^* = B(x^{(k)} - x^*) \\ &= B e^{(k)} = B^{k+1} e^{(0)} \end{aligned}$$

$\forall \varepsilon > 0, \exists$ 一个算子范数 $\|\cdot\|$ 使得 $\|A\| \leq \rho(A) + \varepsilon$

$$\begin{aligned} \|e^k\| &= \|B^k e^{(0)}\| \leq \|B^k\| \|e^{(0)}\| \leq \|B\|^k \|e^{(0)}\| \\ &\approx (\rho(B))^k \|e^{(0)}\| \end{aligned}$$

定义: 称 $R(B) = -\ln \rho(B)$ 为迭代算法的收敛速度.

$\rho(B)$ 越小, $R(B)$ 越大.

定理: 充分条件. 给出了两种事后误差估计的方法.

若 $\|B\| = q < 1$, 则迭代收敛, 且有下列误差估计:

$$\textcircled{1} \|x^* - x^{(k)}\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\|$$

$$\textcircled{2} \|x^* - x^{(k)}\| \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|$$

$$x = Bx + f$$

$\|B\|$ 某种算子范数 $< 1 \Rightarrow \rho(B) < 1 \Rightarrow$ 收敛

$> 1 \nRightarrow \rho(B) > 1$ 无法判断是否收敛.

定理: 充分条件:

若 A 为严格对角占优, 则解 $Ax=b$ 的 Jacobi 和 Gauss-Seidel 迭代均收敛

若 A 严格对角占优, 则 A 的行式 $\neq 0$

证明: 可以证明: 没有记, 看 PPT 或书上, 课上只讲了 Jacobi

§ 松弛法:

Gauss-Seidel 方法:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right]$$

在后面的部分配一个 $a_{ii} x_i^{(k)}$. 加一个减一个.

$$x_i^{(k+1)} = x_i^{(k)} + \frac{1}{a_{ii}} \left[b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right]$$

记为 $r_i^{(k+1)}$.

$= x_i^{(k)} + \frac{1}{a_{ii}} r_i^{(k+1)}$ 相当于在 $x_i^{(k)}$ 上加一个余项生成 $x_i^{(k+1)}$

§ 外推: $x_i^{(k+1)} = x_i^{(k)} + w \frac{r_i^{(k+1)}}{a_{ii}}$ 添加一个.